

Cuantificación de la Resiliencia Cognitiva mediante Biometría Conductual Multimodal y Arquitecturas Predictivas VL-JEPA: Prevención de Ingeniería Social en Fintech

Nicolas Camilo Yanten Santacruz y Nicolle Tatiana Quijano Jacome

Investigación — Seguridad de la Información / Inteligencia Artificial

Resumen

El 68% de los incidentes de ciberseguridad confirmados en 2024 involucran un componente humano. Las soluciones técnicas actuales protegen la infraestructura, pero no miden el estado cognitivo del usuario en el momento de la interacción. Este artículo presenta el Trust & Security Behavioral Lab (TSBL), un framework de detección de Vacilación Cognitiva en tiempo real que integra biometría facial multimodal, telemetría de interacción DOM y la arquitectura VL-JEPA para generar un Score de Resiliencia del Usuario (SRU). La hipótesis central establece que los cambios en el espacio de embeddings conductuales ante estímulos de ingeniería social presentan una divergencia coseno estadísticamente significativa ($p < 0.05$) respecto al comportamiento basal del usuario, con sensibilidad superior al 75% y especificidad superior al 80%. El sistema opera con privacidad en el Edge, sin almacenar biometría cruda, y activa cuatro niveles de Fricción de Seguridad Positiva proporcionales al riesgo detectado.

Palabras clave: biometría conductual, VL-JEPA, resiliencia cognitiva, ingeniería social, Fintech, vacilación cognitiva, FSP, SRU.

I. INTRODUCCION

La ciberseguridad contemporánea ha alcanzado un nivel técnico elevado: firewalls de próxima generación, cifrado extremo a extremo, autenticación multifactorial. Sin embargo, el Verizon Data Breach Investigations Report 2024 documenta que el 68% de los incidentes de seguridad confirmados involucran un factor humano. El IBM Cost of a Data Breach Report 2025 estima que el costo promedio de un incidente de ingeniería social en el sector financiero alcanza los 4.88 millones de dólares por caso.

El problema no es tecnológico: es cognitivo. Estudios de Proofpoint (2024) revelan que el 96% de los usuarios que caen en un ataque de phishing reconocen haber notado algo sospechoso antes de actuar. El usuario percibe la señal de riesgo, pero no activa el razonamiento analítico necesario para procesarla. Las interfaces digitales diseñadas para eliminar la fricción entrenan al cerebro a operar en modo automático, lo que Kahneman (2011) denomina Sistema 1, inhibiendo la activación del pensamiento deliberativo.

Las soluciones actuales atacan este problema desde dos frentes insuficientes: la detección técnica de patrones maliciosos, que cae ante ataques generados por IA (Heiding et al., Harvard, 2024), y la capacitación, cuyo efecto desaparece en menos de seis meses (Lain et al.,

ETH Zurich, 2022). Ninguna mide el estado cognitivo del usuario en el momento de la interacción.

Este trabajo presenta el Trust & Security Behavioral Lab (TSBL), primer framework que integra predicción de embeddings conductuales mediante VL-JEPA, biometría facial multimodal y análisis recursivo de sesiones para cuantificar la resiliencia cognitiva en tiempo real en interfaces Fintech, activando intervenciones adaptativas proporcionales al riesgo detectado.

II. TRABAJOS RELACIONADOS

Arquitecturas predictivas en video. VL-JEPA (Chen et al., Meta FAIR, 2026) demuestra que la predicción en espacio latente supera a los modelos generativos tradicionales en tareas de video con 50% menos parámetros entrenables y una reducción de 2.85x en operaciones de decodificación. V-JEPA 2 (Assran et al., 2025) establece la base de representación temporal sin anotaciones que este proyecto utiliza.

Biometría conductual y phishing. Investigaciones con eye-tracking (Frontiers, 2020) documentan que los usuarios miran indicadores de riesgo, pero invierten tiempo insuficiente en analizarlos. La integración de biometría conductual con análisis de URL mejoró la detección de fraude en un 40% en estudios pre-2022.

Fricción de seguridad. Distler et al. (ACM NSPW, 2020) establecen el framework de Security-Enhancing Friction: la fricción diseñada intencionalmente en momentos críticos reduce comportamientos de riesgo sin deteriorar permanentemente la experiencia de usuario.

Modelos recursivos. Zhang, Kraska y Khattab (MIT, 2026) introducen los Modelos de Lenguaje Recursivos (RLM), que procesan entradas dos órdenes de magnitud más allá de la ventana de contexto convencional mediante llamadas recursivas sobre sub-segmentos almacenados en un entorno externo.

Brecha identificada. Ninguna investigación publicada integra embeddings conductuales de video, correlación con telemetría DOM, intervención activa adaptativa y un indicador de resiliencia validado estadísticamente en un sistema único orientado a Fintech.

III. HIPOTESIS DE INVESTIGACION

La hipótesis principal que guía este trabajo es la siguiente:

H1: Los vectores de embedding conductual generados por el X-Encoder de V-JEPA 2 ante estímulos de

ingeniería social presentan una divergencia coseno estadísticamente significativa ($p < 0.05$) respecto a la línea base de comportamiento normal del usuario, con sensibilidad superior al 75% y especificidad superior al 80% en una muestra de 100 usuarios de plataformas Fintech.

Se plantean tres hipótesis secundarias: (H2) la combinación de biometría facial y telemetría DOM produce mayor AUC que cualquier canal por separado; (H3) la Fricción de Seguridad Positiva reduce la tasa de clics en phishing simulado en al menos 30% respecto al grupo control; (H4) el análisis RLM de sesiones largas incrementa la precisión del SRU en al menos 15% respecto al análisis de ventanas aisladas.

IV. ARQUITECTURA DEL SISTEMA

El TSBL opera en tres capas independientes con tecnologías, temporalidades y responsabilidades distintas. La separación por capas permite construir, validar y mejorar cada componente sin afectar los demás.

Capa	Tecnología	Output	Latencia
1 — Captura	MediaPipe + JS DOM wrapper + WebSocket	Vectores + timestamps	< 50 ms
2 — Embedding	V-JEPA 2 X- Encoder + calculo coseno	Stream embedding s + alertas VC	< 200 ms
3 — Análisis	RLM + LLM API + FSP engine	SRU + reporte forense	1-5 min post-sesion

Tabla I. Resumen de capas del sistema TSBL.

Capa 1 — Captura multimodal. MediaPipe Face Mesh extrae 468 landmarks faciales a 30 fps directamente en el navegador del usuario, sin transmitir imágenes. Un wrapper JavaScript captura eventos DOM con precisión de ± 50 ms usando `performance.now()`. Ambos canales se sincronizan en un servidor local por WebSocket.

Capa 2 — Motor VL-JEPA. El X-Encoder de V-JEPA 2 (ViT-L, pesos congelados) procesa segmentos de 8 segundos de landmarks reconstruidos y produce embeddings de dimensión 1024. El Predictor (capas 8-16 de Llama-3.2-1B, 490M parámetros entrenables) predice el embedding Sy_hat de 1536 dimensiones. La divergencia $\delta(W)$ se calcula como:

$$\delta(W) = 1 - \text{cosine_similarity}(Sy_hat, B_usuario)$$

donde B es la línea base individual construida en los primeros 30 segundos de sesión con contenido neutral. Si $\delta(W)$ supera el umbral θ calibrado individualmente, el sistema registra un episodio de Vacilación Cognitiva.

Capa 3 — Análisis longitudinal. Al cierre de sesión, el componente RLM procesa el historial completo en sub-segmentos de 5 minutos mediante llamadas recursivas, identificando patrones de vulnerabilidad no visibles en

ventanas cortas. El resultado es el Score de Resiliencia del Usuario:

$$SRU = 100 \times [1 - f(N_VC, T_VC, \delta_max, ROT, contexto)]$$

donde N_VC es el número de episodios detectados, T_VC su duración promedio, δ_max la mayor divergencia registrada, y ROT la proporción de elementos de riesgo revisados antes de interactuar con ellos.

V. FRICCIÓN DE SEGURIDAD POSITIVA

La Fricción de Seguridad Positiva (FSP) es el componente de intervención activa del sistema. Se activa únicamente durante episodios de Vacilación Cognitiva, con el objetivo de extender el tiempo de procesamiento del usuario y facilitar la transición hacia el razonamiento analítico antes de que se complete una acción potencialmente riesgosa.

A diferencia de la fricción tradicional que se aplica universalmente y genera habituación, la FSP se activa en el momento en que el cerebro ya está en estado de duda, maximizando su efectividad. El sistema implementa cuatro niveles proporcionales al valor de $\delta(W)$:

- Nivel 1 (δ 0.15-0.25): pausa micro de 800ms, invisible al usuario.
- Nivel 2 (δ 0.25-0.40): resaltado contextual de elementos de riesgo activos.
- Nivel 3 (δ 0.40-0.60): aviso no bloqueante de 4 segundos de duración.
- Nivel 4 ($\delta > 0.60$): bloqueo temporal que requiere confirmación con razonamiento escrito.

Este diseño está fundamentado en el framework de Security-Enhancing Friction de Distler et al. (2020), que demuestra que la fricción bien calibrada temporalmente reduce los comportamientos de riesgo sin deteriorar la experiencia del usuario a largo plazo.

VI. METODOLOGIA

La investigación tiene un diseño cuasiexperimental con enfoque mixto. El componente cuantitativo valida estadísticamente las cuatro hipótesis. El componente cualitativo analiza patrones de comportamiento emergentes en las sesiones.

Fase	Actividad
I — Instrumentación	Wrapper JS, MediaPipe, pipeline WebSocket
II — Captura	100 participantes: 50 expuestos a phishing simulado, 50 control
III — Modelado	Embeddings, calibración de θ , validación H1 y H2
IV — FSP y SRU	Implementación FSP, calculo SRU, prueba A/B, H3 y H4
V — Validación	Análisis estadístico completo

Tabla II. Fases metodológicas del proyecto.

Validación del SRU. Se realiza en tres pasos: (1) correlación con tasa de clics reales, objetivo AUC > 0.80; (2) estabilidad temporal con correlación de Pearson > 0.70 en doble medición con dos semanas de diferencia; (3) sensibilidad a la intervención FSP con $p < 0.05$ entre grupo experimental y control.

Privacidad. El video facial se transforma en landmarks numéricos localmente antes de cualquier transmisión. El servidor nunca recibe imágenes crudas. El sistema cumple el Artículo 9 del GDPR sobre datos biométricos como categoría especial.

VII. JUSTIFICACION DE VL-JEPA

La elección de VL-JEPA como arquitectura central responde a tres restricciones simultaneas del problema que ninguna alternativa cumple en conjunto.

Restricción 1 — Latencia. La Vacilación Cognitiva dura entre 3 y 12 segundos. Un modelo generativo (GPT-4V, LLaVA) tarda entre 800 ms y 3 segundos en producir texto interpretable. VL-JEPA produce un embedding en menos de 200 ms, lo que permite detectar el episodio en su primera mitad.

Restricción 2 — Computación. Los modelos generativos de video requieren A100 o H100 para inferencia en tiempo real. El X-Encoder de V-JEPA 2 en modo de inferencia con pesos congelados corre sobre GPU T4 de Google Colab, disponible gratuitamente.

Restricción 3 — Privacidad. CLIP y SigLIP procesan frames estáticos, perdiendo la dinámica temporal que caracteriza la Vacilación Cognitiva. V-JEPA 2 aprende representaciones temporales mediante autosurvision sin anotaciones, capturando la secuencia de micro expresiones y movimientos que definen el episodio cognitivo.

La Decodificación Selectiva nativa de VL-JEPA —que activa el Y-Decoder solo ante cambios semánticos significativos— reduce adicionalmente las operaciones de inferencia en 2.85x, lo que hace viable el monitoreo continuo en un entorno de laboratorio universitario.

VIII. IMPACTO ESPERADO

Impacto científico. Primera integración documentada de embeddings conductuales de video con telemetría DOM e intervención adaptativa para la detección de vulnerabilidad cognitiva ante ingeniería social.

Impacto social — Colombia. La Superintendencia Financiera de Colombia reporta un incremento del 40% anual en fraude digital. El TSBL ofrece una herramienta de auditoría de seguridad de experiencia de usuario que las plataformas Fintech colombianas pueden integrar para medir la vulnerabilidad real de sus usuarios, no su vulnerabilidad declarada.

Impacto tecnológico. El SDK resultante permite integrar el sistema en cualquier plataforma web mediante un script JavaScript de captura más una API de análisis. El modelo de transferencia tecnológica incluye licenciamiento B2B a entidades financieras y organismos reguladores.

Viabilidad. El proyecto no requiere infraestructura de GPU propia. MediaPipe corre en el navegador. El X-Encoder corre en Colab T4 gratuito. El RLM usa API de LLM externa. El costo operativo estimado es menor a \$183.560 COP mensuales durante la fase de investigación.

IX. CONCLUSIONES Y TRABAJO FUTURO

Este artículo presenta el Trust & Security Behavioral Lab, un framework que redefine el enfoque de la ciberseguridad centrada en el usuario al medir el estado cognitivo en tiempo real en lugar de capacitar de forma reactiva. La arquitectura VL-JEPA permite detección de Vacilación Cognitiva con la latencia, el costo computacional y las garantías de privacidad que un despliegue real en Fintech requiere.

La contribución metodológica —hipótesis falsificable, protocolo de validación en tres pasos, diseño cuasiexperimental con grupo control— asegura que los resultados sean reproducibles y publicables en el nivel científico que el proyecto merece.

El trabajo futuro incluye la extensión del framework a múltiples idiomas y contextos culturales, la validación en condiciones de campo real con entidades financieras colombianas, y la exploración de fine-tuning del X-Encoder con datasets de sesiones de usuario en interfaces digitales.

REFERENCIAS

- [1] Verizon, "Data Breach Investigations Report 2024," Verizon Business, 2024.
- [2] IBM Security, "Cost of a Data Breach Report 2025," IBM / Ponemon Institute, 2025.
- [3] Proofpoint, "2024 State of the Phish Report," Proofpoint Inc., 2024.
- [4] F. Heiding, B. Schneier y A. Vishwanath, "Devising and Detecting Phishing: Large Language Models vs. Smaller Human Models," Harvard Kennedy School Belfer Center, 2024.
- [5] D. Lain, K. Kostainen y S. Capkun, "Phishing in Organizations: Findings from a Large-Scale and Long-Term Study," IEEE Symp. Security and Privacy, 2022.
- [6] D. Chen et al., "VL-JEPA: Joint Embedding Predictive Architecture for Vision-Language," arXiv:2512.10942v2, Meta FAIR, 2026.
- [7] M. Assran et al., "V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning," arXiv:2506.09985, Meta FAIR, 2025.
- [8] A. L. Zhang, T. Kraska y O. Khattab, "Recursive Language Models," arXiv:2512.24601v2, MIT CSAIL, 2026.
- [9] V. Distler et al., "The Framework of Security-Enhancing Friction," ACM NSPW, 2020.
- [10] D. Kahneman, Thinking, Fast and Slow. Farrar, Straus and Giroux, 2011.
- [11] Superintendencia Financiera de Colombia, "Informe de Riesgos Cibernéticos en el Ecosistema Financiero Digital," 2025.